🏦 MISIÓN DE CONSULTORÍA: EL MISTERIO DE LA FUGA DE CLIENTES

Cliente: Junta Directiva del Banco Externado

Rol: Equipo de Analistas de Datos (Data Scientists)

Tiempo límite: Hasta las 9 a.m.

📄 Contexto del Negocio

El Banco Externado se enfrenta a una crisis sin precedentes. En el último trimestre, la tasa de abandono de clientes (fuga) se ha disparado. Cada cliente que cierra sus cuentas representa una pérdida enorme en valor presente neto para la entidad. La Junta Directiva necesita entender **quiénes** se están yendo y **por qué**, para poder diseñar una política de retención urgente.

El departamento de Ingeniería de Sistemas logró extraer la información de los clientes, pero como suele ocurrir en la vida real, los datos son un desastre. Vienen en dos archivos separados, tienen valores nulos, formatos extraños y errores de digitación.

Su misión: Limpiar, integrar, transformar y explorar estos datos para presentar un diagnóstico económico a la Junta Directiva antes de que cierre la bolsa de valores (al finalizar la clase).

💾 Diccionario de Datos

Han recibido dos archivos:

1. banco_clientes.csv (Información Demográfica del Cliente)

- ID_Cliente: Identificador único del usuario.
- Edad: Edad del cliente en años.
- Ingreso_Mensual: Ingresos mensuales estimados en pesos.
- Genero: Género del cliente.

2. banco_transacciones.csv (Información de Comportamiento del Cliente)

- ID_Cliente: Identificador único del usuario.
- Saldo_Cuenta: Dinero promedio en la cuenta.
- Cant_Productos: Número de productos activos (tarjetas, créditos, CDT, etc.).
- Fuga_Ultimo_Mes: Variable objetivo. 1 si el cliente abandonó el banco, 0 si continúa activo.

🚀 LOS 5 RETOS (Entregables)

Deberán trabajar en equipos de 3 personas en un único **Jupyter Notebook**.

Reto 1: Integración de la Información (Data Merging)

La información separada no sirve.

1. Importen ambos archivos usando pandas.
2. Realicen la unión de las dos tablas usando el ID_Cliente como llave. Asegúrense de no perder a los clientes que están en la base demográfica pero no tienen transacciones recientes (Pista: piensen en qué tipo de merge o join necesitan).
3. Hagan un print de las dimensiones del dataframe (número de filas y columnas).
4. Muestre las 3 primeras filas del dataframe.

Reto 2: Limpieza (Data Cleaning)

Nuestros modelos de Machine Learning futuros odian la basura. Deben dejar la base impecable:

1. **Estandarización:** La columna Genero fue llenada a mano y tiene inconsistencias. Unifíquenla para que solo existan las siguientes 3 categorías: Femenino, Masculino, Otro.
2. **Valores Nulos:** Hay clientes sin Edad, Ingreso_Mensual, Saldo_Cuenta, Cant_Productos y Fuga_Ultimo_Mes. Imputen (rellenen) estos vacíos. Asuma que si no hay información de las transacciones es porque el cliente no tiene productos financieros actualmente con el banco. Agreguen un comentario en el código justificando qué método usaron para cada variable (por ejemplo, si usaron la media, la mediana, un valor en específico) y por qué tiene sentido hacerlo así.
3. **Outliers:** Hay un cliente que supuestamente tiene 150 años. Encuentren el error y corríjanlo lógicamente. Agreguen un comentario en el código justificando qué método usaron para corregir el outlier y por qué tiene sentido hacerlo así.

Reto 3: Transformación (Data Manipulation)

1. Creen una nueva columna llamada Ingreso_Anual (asumiendo 12 meses).
2. La Junta quiere un resumen rápido: Creen una tabla agrupada (groupby) que muestre el **Saldo promedio** en la cuenta, agrupado por Genero y por si el cliente se fugó o no (Fuga_Ultimo_Mes).

Reto 4: Análisis Exploratorio - EDA

1. Grafiquen un **diagrama de barras** que muestre la proporción de fuga según la Cant_Productos que tiene el cliente.

2. Construyan un **boxplot** que compare el Ingreso_Mensual de los clientes que se fugaron frente a los que se quedaron.
3. Analicen las dos gráficas anteriores y redacten un *Pitch Económico* para la junta directiva. No describan la gráfica ("la barrita azul es más alta"), expliquen la *razón subyacente*.
4. Basándose en los datos, ¿qué medidas le recomiendan tomar a la junta directiva para reducir o evitar la fuga de clientes?

Reto 5: Preparación para Machine Learning (Feature Engineering)

Dejen la base lista para aplicar posteriormente los algoritmos de Machine Learning.

1. Las máquinas no leen texto. Apliquen *One-Hot Encoding* (Variables Dummy) a la columna Genero. Haga lo necesario para que no se generen problemas de multicolinealidad exacta.
2. Escalen/Normalicen las columnas Ingreso_Mensual y Saldo_Cuenta para que estén en magnitudes comparables. (Pueden usar *MinMaxScaler* o *StandardScaler*).

🏆 CÓMO GANAR LA DATATÓN

Suba el Jupyter Notebook a su cuenta en Github y envíe el link en el siguiente Forms:

https://forms.office.com/r/xgrbHXtF1i

El equipo ganador será el que cumpla las siguientes condiciones:

- Respondió correctamente todos los puntos.
- Realizó un buen análisis y argumentación en los puntos donde se solicita.
- Fue el más rápido en entregar.

Premio al equipo ganador: + 5 décimas en la nota del segundo parcial o de talleres del segundo corte (a elección del equipo).

¡El tiempo corre. Mucha suerte, analistas!